

Comparaison de trois méthodes multi-blocs supervisées

Classification de la localisation tumorale pédiatrique (cort / dipg / midl) à partir des blocs GE (15 702 features) et CGH (1 229 features) de la cohorte IGR (n=53 patients : 39 train, 14 test).

1. Les trois approches comparées

Cooperative Learning (Lasso OvR) - NB11

Régression logistique binomiale Lasso en stratégie one-vs-rest : trois modèles binaires indépendants (cort vs reste, dipg vs reste, midl vs reste), chacun avec son λ optimisé par CV interne. Implémentation R via le package multiview, fixé à $\rho = 0$ (le solveur glmnet ne converge pas pour $\rho > 0$). Prédiction finale par argmax des trois probabilités sigmoïdes.

LogReg multinomiale - NB14a

Régression logistique multinomiale Elastic Net avec softmax, optimisation jointe sur les trois classes. Implémentation R via glmnet sur la concaténation des blocs (16 931 features). Pas de cooperative learning, sélection sparse directe par L1.


SGCCA + LDA - NB09 (méthode du tuteur)

Sparse Generalized Canonical Correlation Analysis (RGCCA), décomposition supervisée multi-blocs : composantes sparses par bloc optimisant la covariance avec un bloc y (one-hot encodé). Classification finale par LDA dans l'espace 2D des composantes. Hyperparamètres : sparsity_GE, sparsity_CGH sélectionnés via rgcca_cv() en 7-fold $\times$ 3 runs.

Protocole identique pour les trois : validation croisée stratifiée 7-fold $\times$ 3 répétitions (21 folds) sur le train, test set tenu à part (n=14).


2. Performance comparée

Performance des trois approches multi-blocs



Cooperative Lasso (NB11) et SGCCA + LDA (NB09) atteignent strictement la même balanced accuracy en cross-validation (0.833 ± 0.129 vs 0.829 ± 0.133 , statistiquement indistinguables) et sur le test set (0.924 dans les deux cas). LogReg multinomiale (NB14a) plafonne à 0.773 sur le test, soit un déficit de 0.15 par rapport aux deux autres méthodes. La CV de NB14a n'a pas été partagée et reste à compléter.

3. Sensibilité aux hyperparamètres principaux



Panneau gauche - Cooperative Lasso : sensibilité à ρ

Le paramètre ρ contrôle le poids du terme d'agrément cross-blocs $\rho/2 \cdot \|X \cdot \theta_{GE} - Z \cdot \theta_{CGH}\|^2$. À $\rho = 0$, cooperative dégénère en Lasso multi-bloc standard. Pour $\rho > 0$, le solveur glmnet (utilisé en interne par multiview) ne converge pas dans son nombre maximum d'itérations (100 000), à cause du mauvais conditionnement induit par l'agrément. La région $\rho > 0$ reste donc inexplorée avec cette implémentation. La performance optimale 0.833 est atteinte à $\rho = 0$.

Panneau milieu - LogReg multinomiale : sensibilité à α


Le paramètre α de glmnet contrôle le mélange Lasso ($\alpha=1$) / Ridge ($\alpha=0$) de la pénalisation Elastic Net. Le sweep complet n'a pas été partagé pour ce notebook ; pour information, l'optimum trouvé en CV interne est $\alpha = 1$ (Lasso pur), donnant un test bal_acc de 0.773.

Panneau droit - SGCCA + LDA : sensibilité à la sparsité

rgcca_cv() teste 10 sets de paramètres (sparsity_GE, sparsity_CGH) uniformément espacés entre $1/\sqrt{p}$ et 0.2. Un plateau optimal apparaît aux Sets 8-9 ($s_{GE} \approx 0.04 - 0.05$), correspondant à ~68 gènes et ~11 régions CGH retenus. La sparsité trop lâche (Sets 1-4) et trop forte (Set 10) dégradent les performances. SGCCA montre une sensibilité bien calibrée et modulable à la sparsité, contrairement à Cooperative qui est plafonné à $\rho = 0$.

4. Matrices de confusion sur le test (n=14)


Matrices de confusion sur le test set (n=14)



Cooperative Lasso et SGCCA + LDA produisent des matrices strictement identiques sur le test : 5/5 cort, 6/6 dipg, 2/3 midl. Le seul patient midl mal classé est attribué à dipg. LogReg multinomiale montre un pattern d'erreurs totalement différent : 0/3 midl reconnu, et erreurs supplémentaires (1 cort vers midl, 2 dipg vers midl).

5. Recall par classe — focus sur midl

Recall par classe — focus sur la classe minoritaire midl




Le recall par classe révèle la différence structurelle entre les méthodes :

- Cooperative Lasso et SGCCA atteignent recall = 1.00 sur cort et dipg, et 0.67 sur midl (2 patients sur 3 correctement identifiés).
- LogReg multinomiale chute à 0.83 sur cort, 0.75 sur dipg, et 0.00 sur midl (aucun patient midl reconnu).

Cette différence s'explique par la formulation OvR + argmax de Cooperative et SGCCA, qui permet à la classe minoritaire midl d'être prédite "par exclusion" lorsque les classifieurs des autres classes la rejettent simultanément. La formulation multinomiale avec softmax couple les probabilités via la contrainte $\sum P(c) = 1$, ce qui pénalise structurellement la classe sous-représentée (8 patients midl train sur 39).

6. Parcimonie effective

Parcimonie effective des trois méthodes



Cooperative Lasso est la méthode la plus parcimonieuse sur GE : 42 variables retenues (union de 24 cort + 18 dipg + 0 midl - le classifieur OvR midl s'effondre à $\beta=0$, sauvé uniquement par son intercept calibré sur la prévalence). LogReg

multinomiale retient 27 variables par classe (avec `type.multinomial = 'grouped'`). SGCCA garde 68 GE par contrainte structurelle de couvrir le bloc.

Constat important : Cooperative et LogReg multinomiale ne retiennent AUCUNE variable CGH. Seul SGCCA garde 11 régions CGH, par contrainte de couvrir les deux blocs. Cela suggère fortement que CGH n'apporte pas d'information complémentaire à GE pour cette tâche.

7. Tableau récapitulatif

Méthode	CV bal_acc	Test bal_acc	midl recall	Vars GE	Vars CGH
Cooperative Lasso (NB11)	0.833 ± 0.129	0.924	2/3	42	0
LogReg multinomiale (NB14a)	non partagée	0.773	0/3	27	0
SGCCA + LDA (NB09)	0.829 ± 0.133	0.924	2/3	68	11

8. Conclusions méthodologiques

a) Cooperative Lasso et SGCCA convergent vers la même solution

Les performances en CV (0.833 vs 0.829) et sur le test (0.924 vs 0.924) sont indistinguables. Cette équivalence est attendue théoriquement : à $p = 0$, cooperative learning dégénère en Lasso multi-bloc supervisé avec sparsité L1 par bloc, formulation conceptuellement proche de SGCCA. Les deux méthodes capturent la même structure prédictive sur ce dataset.

b) La formulation OvR + argmax est cruciale pour la classe minoritaire

L'écart de 0.15 entre Cooperative/SGCCA (0.924) et LogReg multinomiale (0.773) est entièrement attribuable au comportement sur la classe midl (recall 2/3 vs 0/3). La formulation OvR permet à l'intercept du classifieur midl - qui s'effondre à $\beta = 0$ par CV interne - de servir de seuil constant (~ 0.20) que les autres classifieurs doivent battre. Pour un patient midl, les classifieurs cort et dipg produisent $P \approx 0.05-0.10$, ce qui fait gagner midl par exclusion. La normalisation softmax du multinomial natif rend ce mécanisme impossible.

c) Le bloc CGH n'apporte pas d'information complémentaire à GE

Cooperative et LogReg multinomiale retiennent 0 variable CGH dans leurs modèles finaux. SGCCA en garde 11 par contrainte structurelle mais l'optimum trouvé en CV est précisément à la limite de la grille (Set 8 : sparsity_CGH = 0.067, minimum testé pertinent). Le signal discriminant entre cort, dipg et midl est porté quasi-exclusivement par l'expression génique.

d) Limitations identifiées

- Test set de seulement 14 patients : intervalle de confiance bootstrap sur balanced accuracy d'environ ± 0.15 . L'écart 0.829 vs 0.833 entre SGCCA et Cooperative n'est pas significatif ; l'écart 0.773 vs 0.924 face à LogReg multinomiale l'est largement.
- Cooperative non explorable pour $p > 0$: le solveur glmnet ne converge pas dans son nombre maximum d'itérations à cause du mauvais conditionnement induit par le terme d'agrément.
- Plafond performance limité par midl (n=8 train) : aucune méthode n'atteint midl 3/3 sur le test set. Le plafond ~ 0.92 reflète cette limite structurelle.

9. Suite envisagée

Tests statistiques de comparaison

Pour quantifier rigoureusement l'équivalence Cooperative $\approx$ SGCCA, un test de Wilcoxon paired sur les 21 folds de CV des deux méthodes serait approprié. Nécessite les scores individuels par fold (actuellement disponibles uniquement en moyenne $\pm$ sd).

Validation biologique

Bootstrap stability sur les loadings de SGCCA via `rgcca_bootstrap()` pour identifier les variables stables avec p-values FDR. Enrichissement GO/GSEA sur ces variables (signature H3K27M pour DIPG, neurogenèse pour cort, FOXG1/glycolyse pour midl).

Validation externe

Cohorte indépendante (OpenPBTA, CBTTTC ou cohorte St-Jude pédiatrique) pour confirmer que les variables identifiées par SGCCA généralisent au-delà de l'IGR.